

Aplicación Android para recomendación de prendas de vestir usando aprendizaje profundo

Trabajo Terminal No.

Alumno: Burciaga Ornelas Rodrigo Andrés *

Directores: Dr. Suárez Castañón Miguel Santiago, Dr. Carlos Alberto Duchanoy Martínez,

Turno para la presentación del TT: Matutino

e-mail: andii_burciaga@live.com*

Resumen – Este Trabajo Terminal creará una aplicación móvil para el sistema operativo Android que ayude a recomendar prendas de vestir similares (parte superior, parte inferior y zapatos), utilizando únicamente como entrada una imagen la cual el usuario podrá subir a la aplicación, para de esta manera reconocer las prendas en la imagen y basado en el estilo de las mismas, recomendar prendas de ropa similares encontradas en un repositorio de datos, la información a recomendar (prendas de vestir) será desplegada en la aplicación android.

Palabras clave – Aplicación Android, Deep Learning, Sistema de recomendación.

1. Introducción

El machine learning es un subcampo de la Inteligencia Artificial preocupado por algoritmos que permitan a las computadoras aprender. Esto significa en la mayoría de los casos, que un algoritmo recibe un conjunto de datos e infiere información sobre las propiedades de los datos y esa información le permite hacer predicciones sobre otros datos que podrían verse en el futuro [1].

El Aprendizaje Profundo (*Deep Learning*), es una rama del machine learning que permite enseñar a las computadoras cosas que los humanos somos capaces de hacer a través de modelos informáticos que funcionan de forma similar al cerebro humano, así que, si una persona puede identificar estas características de manera exitosa, un modelo basado en aprendizaje profundo también puede extraer estas características. Deep Learning emergió como una herramienta para resolver problemas de percepción, ya que es un conjunto de familias que son adaptativas.

Las Redes Neuronales Artificiales son una abstracción de las neuronas biológicas implementadas como parte de un programa; su utilidad radica en la capacidad que tienen de ser entrenadas para realizar funciones de utilidad [2], su principal característica es simular el modelo neuronal del cerebro, el cual es la base principal para que un ser humano pueda realizar sus funciones cognitivas.

Las Redes Neuronales Convolucionales (*CNN por sus siglas en inglés*) son un modelo de Redes Neuronales Artificiales ideales en cuanto a procesamiento de imágenes y reconocimiento de patrones en las mismas, debido a que ofrecen mejoras en relación a otras Redes Neuronales Profundas con respecto a su rendimiento y tamaño reducido del modelo [3].

Los sistemas de recomendación son unas de las herramientas más importantes que ayudan a resolver el problema de la excesiva información no estructurada en internet. En la mayoría de los sitios web, una gran variedad de recomendaciones se encuentran presentes, los sitios recomiendan sus motores para búsqueda de canciones, música, productos y además publicidad [4].

Con el aumento exponencial en la cantidad de información digital a través de internet; las tiendas de música en línea, bibliotecas de video e imágenes, así como la mayoría de los comercios electrónicos se han visto en la necesidad de implementar motores de búsqueda y sistemas de recomendación que ayuden a los usuarios a encontrar información relevante para ellos en poco tiempo.

En general, las recomendaciones se pueden basar en las preferencias de usuario, las características de los artículos, transacciones pasadas, y otros factores ambientales como el tiempo, la temporada, la locación, etc. En las literaturas, los sistemas de recomendación son clasificados en 3 categorías principales: filtros colaborativos (usando únicamente la interacción de los artículos del usuario para recomendaciones), contenido en base a (usando las preferencias de usuario,

preferencias de artículos o ambas) y modelos de recomendación híbridos (usando información de la interacción como también información de los artículos). Los modelos bajo estas categorías tienen sus propias limitaciones como la escasez de datos e inicio frío, que es cuando no se pueden realizar inferencias para usuarios o temas sobre los cuales aún no se ha reunido suficiente información [5].

Dados los avances del aprendizaje profundo en varios campos de aplicación como la visión por computadora y procesamiento de lenguaje natural, el aprendizaje profundo se ha extendido a áreas como recuperación de información y sistemas de recomendación. El impacto general de integrar el aprendizaje profundo en los sistemas de recomendación se puede observar sobre las mejoras en los sistemas convencionales presentados anteriormente (filtros colaborativos, contenido en base a e híbridos).

La mayoría de los motores de búsqueda de compras en línea todavía dependen en gran medida de una base de conocimientos y utilizan la coincidencia de palabras clave como estrategia de búsqueda para encontrar el producto más probable que los consumidores desean comprar. Esto es ineficiente debido a que la descripción de los productos puede variar mucho del lado del vendedor al lado del comprador [6].

La industria de la moda es una de las que tienen mayores ingresos a la economía de un país, en el año 2017 los mexicanos gastaron un total de 345 billones de pesos en ropa, lo cuál constituye un porcentaje del 3% de los gastos básicos de una persona durante ese año [7].

Una gran parte de las ventas en el dominio del comercio electrónico está impulsada por la moda y el estilo de vida, que constituye indumentaria, calzado, bolsos, accesorios, etc. Específicamente en México, el valor de mercado del comercio electrónico de la industria de ropa proyectó durante el año 2018 un alcance de 704 millones de dólares. Sin embargo, una importante estadística indica que en promedio una persona compra entre 35 y 40 prendas de ropa al año, pero se tiran aproximadamente 14 kilos de ropa al año [8]. Esto se debe en mayor parte a una mala elección del producto al momento de la compra.

No obstante, la industria textil está dentro de las 3 industrias más contaminantes del mundo, el “bajo precio” de la ropa permite que las personas compren prendas sin antes pensar en muchas ocasiones si en verdad es de su agrado o es necesaria la prenda; este “bajo costo” termina generando un costo más alto en el medio ambiente [9].

La industria de la moda se caracteriza por promover el consumo a través de sus constantes cambios de temporada lo que ha impulsado el “fast fashion”, prendas que se producen de forma rápida y que al ser de bajo costo también se adquieren rápidamente, lo cual genera una sensación de que la ropa es “desechable” y ahí viene otro gran daño, ya que las prendas que no usamos terminan en vertederos. El estadounidense promedio tira 37 kilos de desechos textiles al año y como la mayoría de estos desechos no son biodegradables, pueden llegar a demorar siglos en descomponerse, sin olvidar que emiten gases nocivos al aire [9].

Estas alarmantes cifras están provocando que los grandes productores de moda, realicen la ropa con mayor calidad, además de promover el uso constante de una prenda de ropa y el cuidado de las mismas, volviéndolas más valiosas y de mayor duración para el cliente, esto como consecuencia deriva en que la elección de la prenda tiene que ser aún más minuciosa, para que el cliente no se desprenda rápidamente de ella, por ende el proceso de recomendación, elección y compra se vuelve en una parte crítica para la industria textil y en el medio ambiente.

Una característica diferenciadora de la categoría de moda al momento de elegir un producto, es que la decisión de compra de un usuario está principalmente influenciada por la apariencia visual del producto. Por lo tanto, es crucial que en una tienda de ropa física o en línea se tenga un sistema de recomendaciones que tenga en cuenta las características visuales presentes en las imágenes asociadas con estos elementos [10].

En este trabajo terminal se propone un motor de búsqueda inteligente para un sistema de recomendaciones en el cuál a un usuario se le puedan recomendar productos de moda similares (almacenados en una base de datos) basados en una imagen la cual tiene prendas que muy probablemente el usuario desee comprar o le agraden, además el usuario podrá subir su foto

con la finalidad de recomendarle productos afines a sus gustos, esto con el propósito de ofrecer una mejor experiencia de usuario, ayudando a que se tenga una mejor elección en la prenda de ropa a comprar, evitando el problema de escasez de datos e inicio frío, además de reducir el porcentaje de prendas que son desechadas o aquellas que no son compradas debido a que el cliente final no se ha percatado de la existencia de las mismas.

Sistemas similares desarrollados:

- Magic Mirror: A Virtual Fashion Consultant
- Augmented Reality: Kinect fitting-room for TopShop
- Zara: Augmented Reality
- ASOS
- Deep Learning based Large Scale Visual Recommendation and Search for E-Commerce
- Image-based Product Recommendation System with Convolutional Neural Networks

| SOFTWARE | RESUMEN | CARACTERÍSTICAS |
|--|--|--|
| Magic Mirror: A Virtual Fashion Consultant [11] | Sistema de recomendación basado en qué prendas deberías usar, utilizando realidad aumentada y kinect | <ul style="list-style-type: none"> • Recomienda prendas basado en la apariencia física de la persona y la temporada del año (lo más usado en una tienda de ropa) usando realidad aumentada |
| Augmented Reality: Kinect fitting-room for TopShop [12] | Probador de ropa con realidad aumentada sólo para mujeres | <ul style="list-style-type: none"> • Permite probar prendas con realidad aumentada • No recomienda, puedes probarte lo que se encuentra disponible únicamente • Funge como espejo |
| Zara: Augmented Reality [13] | Modelador de personas en realidad aumentada para observación de prendas | <ul style="list-style-type: none"> • Crea personas virtuales para modelado de prendas de interés • Únicamente se visualizan dentro de la tienda en los apartados disponibles para realidad aumentada |
| ASOS [14] | Sistema de recomendación de prendas basado en similitudes de imágenes | <ul style="list-style-type: none"> • Recomienda prendas basado en la imagen del usuario • Sugiere muy adecuadamente productos similares • Se pueden agregar nuevos productos al conjunto de datos |
| Deep Learning based Large Scale Visual Recommendation and Search for E-Commerce [10] | Sistema de búsqueda visual y de recomendaciones de prendas para comercio electrónico | <ul style="list-style-type: none"> • Reconocimiento de prendas en diferentes poses • Localización de los objetos en diferentes tipos de imágenes • End to end (sistema productivo) • Sugerencias de prendas basadas en detalles |
| Image-based Product Recommendation System with Convolutional Neural Networks [15] | Sistema de recomendación de prendas basado en ranking | <ul style="list-style-type: none"> • Recomendaciones basadas en ranking • Falta detección de objetos • Recomendaciones a productos similares |
| Trabajo Terminal [propuesta]: Aplicación Android para recomendación de prendas de vestir usando aprendizaje profundo | Sistema de recomendación de prendas similares con aprendizaje profundo | <ul style="list-style-type: none"> • Aplicación Android para detección de prendas • Presentación de productos similares mediante aplicación android • Sistema de recomendación con aprendizaje profundo • Detección de objetos en las imágenes |

Tabla 1. Resumen de productos similares.

Los proyectos, aunque tienen algunas características compartidas, en general varían de acuerdo a la metodología, modelo y el proceso utilizado, la forma en que operan y como presentan los resultados.

2. Objetivo

Desarrollar una aplicación móvil para el sistema operativo Android capaz de hacer recomendaciones de prendas similares (previamente almacenadas en una base de datos) basándose en el estilo de ropa que se encuentra en una imagen, ayudando así a mejorar la experiencia de usuario al encontrar prendas parecidas en color, forma y tipo que sean afines a los gustos del usuario, evitando así el inicio frío y encontrando de forma eficaz los productos más adecuados para el cliente, mejorando así la experiencia de compra encontrando productos que muy probablemente el usuario desee comprar.

Objetivos Particulares

- Generación de bases de datos para el almacenado de la información (prendas a sugerir).
- Generación de dataset necesario para el entrenamiento de la red.
- Generación de REST API para recomendaciones y recuperación de prendas a sugerir.
- Generación de una red neuronal capaz de detectar los objetos del usuario (playera, pantalón y tenis) para poder sugerir los productos más parecidos a su estilo que se encuentren en la base de datos.
- Generación del algoritmo para recomendación de prendas dependiendo de como hayan sido clasificadas en su estilo.
- Crear una aplicación Android que funge como facilitadora de los datos obtenidos por la red neuronal, capaz de mostrarle al usuario productos similares a los de la imagen subida.
- Generar la documentación necesaria (manuales de usuario, funcionamiento del sistema, modelo empleado, pruebas).

3. Justificación

La industria textil representa un gasto elevado y muy concurrido de las personas en comercios electrónicos y físicos esto debido a que es un bien necesario; tan solo en México en el año 2018 del total invertido en productos de consumo masivo (alimentos, bebidas, lácteos, cuidado personal y del hogar) las familias destinaron un poco más del 8% de sus gastos en ropa y calzado, de acuerdo con un estudio de Kantar Worldpanel, publicado en el mes de julio del 2018 [16]. Esto significa que es uno de los bienes necesarios en los que más gastan su dinero las personas después de productos indispensables como comida, artículos de aseo personal, etc.

En promedio al año se fabrican 150.000 millones de prendas. Es decir, 62 millones de toneladas de ropa y complementos; de las cuales el total de ellas se venden rebajando su precio original al 30% y el otro 30% nunca llega a venderse, ese 30% es una distorsión entre la oferta y la demanda que le cuesta a esta industria 210.000 millones de dólares anuales. La mayoría de las prendas que no llegan a venderse es porque las tiendas físicas y comercios electrónicos no encuentran el objetivo deseado (cliente), esto se da por el fenómeno de sobre producción; al haber demasiadas tipos de prendas de vestir en una tienda, muchas veces el usuario no se percata de los productos que probablemente a él le podrían agradar o simplemente no se encuentran a la vista del mismo [16].

460.000 millones de dólares es lo que la economía mundial pierde cada año por las prendas que la industria y la gente tira cuando podrían seguir usándolas perfectamente. El 50% de la ropa que fabrican las cadenas de fast fashion (H&M, Zara, etc) acaba en la basura en menos de un año. Eso son 12.8 millones de toneladas de desperdicios que van a parar a vertederos de todo el mundo. La mayoría de la ropa que acaba en la basura se debe a una pobre conciencia del cliente sobre lo que está comprando y a que en demasiadas ocasiones las tiendas de ropa hacen recomendaciones que los usuarios adoptan inconscientemente, pero después terminan por no convencerlos o no empatan con su estilo de vestimenta [16]. Las últimas cifras han dado un mínimo despunte de la tendencia, lo que ha llevado a muchos medios a propagar que la gente se ha cansado de comprar moda efímera y se está pasando a apreciar mejor cada prenda de ropa de su armario (elegir mejor que se desea comprar) [16].

Al momento de adquirir una nueva prenda de ropa, la mayor parte del tiempo las personas basan su decisión en recomendaciones hechas por el personal de la tienda o sistemas de recomendación. En muchas tiendas de ropa físicas y en línea se encuentran en existencia miles de productos de ropa, los cuales son difíciles de recordar para un vendedor y para los sistemas es difícil hacer una recomendación cuando no se conocen las preferencias del usuario [7]. Esto dificulta el tener una visión de que prenda de ropa es más probable que le agrade al cliente.

Los motores de búsqueda tradicionales de comercio electrónico fallan en este aspecto ya que sólo soportan búsquedas basadas en texto que hacen uso de los metadatos del producto como sus atributos y descripciones, este tipo de métodos son menos efectivos, especialmente para la categoría de moda debido a que las descripciones de los productos con contenido visual son difíciles de crear o no están disponibles.

Ofrecer muchos productos puede reducir la probabilidad de compra, así, finalmente conocer al cliente y ofrecerle los mejores productos situados a sus necesidades y preferencias representa un incremento en la aceptación del cliente con la compañía lo cual es un factor importante para la rentabilidad de la misma [17]. Estudios anteriores demuestran que los motores de recomendación ayudan a los consumidores a tomar mejores decisiones, reducir los esfuerzos de búsqueda y encontrar los precios más adecuados [18]. Por lo tanto identificar los productos que más le gustan un cliente en específico puede incrementar significativamente las ganancias de una compañía, del mismo modo, es claro que recomendar los productos adecuados en un comercio físico y/o electrónico incrementa la probabilidad de compra de un cliente [19].

Como anteriormente se ha mencionado, las prendas de ropa se encuentran entre los productos más buscados y comprados en comercios físicos y electrónicos, sin embargo es de vital importancia hacer recomendaciones de prendas de vestir adecuadas al usuario final, para que la prenda tenga un buen uso y no termine siendo un desperdicio(basura) y además ayude a mejorar la experiencia de usuario y aumentar la probabilidad de compra de una prenda en determinada tienda en línea o física.

Una posibilidad para inferir el conocimiento sobre las preferencias del cliente es a través de preguntas específicas en encuestas a clientes, sin embargo, esto no siempre es posible y las respuestas de los clientes pueden ser incorrectas o insuficientes para describir con precisión las preferencias, así como la negación a responder las mismas lo cual nos representa un problema específico planteado anteriormente conocido “inicio frío”.

Al momento del usuario adquirir una nueva prenda de ropa, es extremadamente probable que se base mucho en las prendas que utiliza en ese instante, esto debido a que tiende a tener gustos similares; así, en este TT, se sigue un enfoque diferente basado en datos no estructurados “imágenes”, donde las preferencias del cliente se extraen automáticamente de la información disponible en la imagen “vestimenta”, para así poder presentarle recomendaciones que se asemejen a sus gustos y mejorar la experiencia de usuario, reducir tiempos de búsqueda y encontrar rápidamente los artículos más adecuados para el cliente.

Este sistema de recomendación ayudará a reducir el porcentaje de prendas ropa que una tienda en línea o física no logran vender (30% aproximadamente), y a prevenir que el usuario realice una compra que él no deseaba sólo porque fue la recomendación de algún individuo, además de tener una visión más amplia de productos que el usuario muy probablemente esté buscando y qué no pudo localizar en la tienda en línea o física.

4. Productos o Resultados esperados

- Aplicación móvil para recomendación de prendas de ropa similares (pantalón, zapatos y playera).
- Manual de usuario.
- Dataset
- Manual técnico.
- Base de datos.
- Código fuente.

En la figura 1, se muestra de manera general la arquitectura que tendrá el sistema a grandes rasgos, para poder realizar las funciones necesarias.

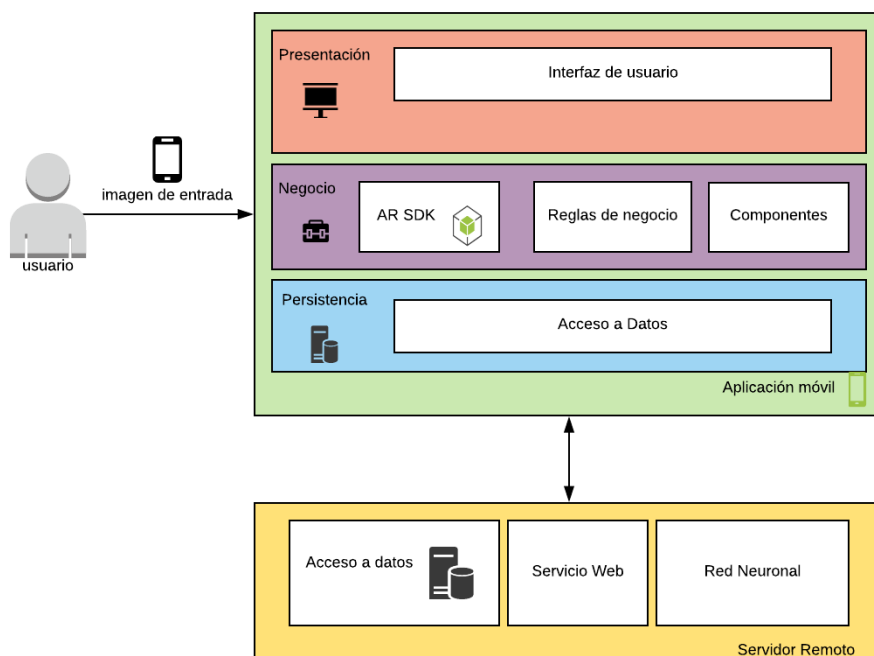


Figura 1. Arquitectura general de la aplicación móvil

En la Figura 2 se muestra la arquitectura general de la red neuronal que se utilizará para el reconocimiento de los objetos (prendas) y sus características:

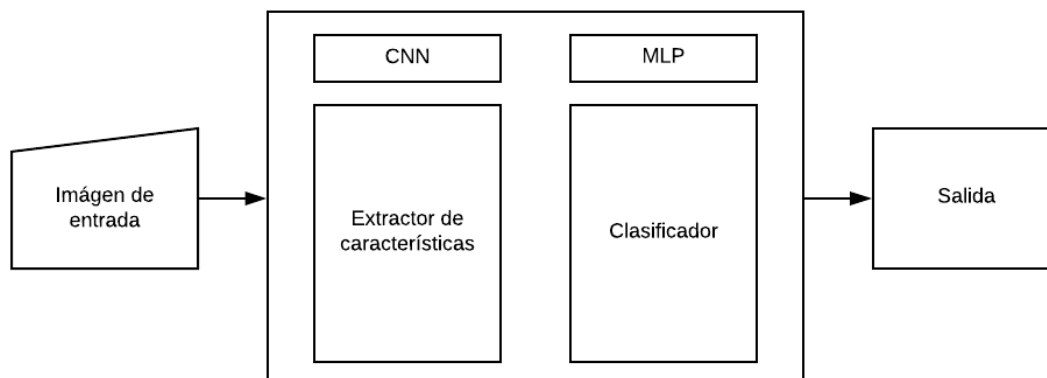


Figura 2. Arquitectura general de la red neuronal

Descripción de los bloques de la figura:

1. **Extractor de características:** Red Neuronal Convolutiva (CNN) adecuada para el entrenamiento y poder detectar los objetos a analizar (pantalón, playera y zapatos) para después ser clasificados y recomendar los productos más adecuados dependiendo de su clasificación.

2. Clasificador: Perceptrón Multicapa (MLP) capaz de obtener las características de las imágenes y clasificarlas dependiendo de las necesidades (clasificar las prendas dependiendo de su tipo).
3. Salida: Conjunto de imágenes con prendas para recomendación al usuario.

5. Metodología

El proceso de construcción del software requiere, identificar las tareas que se han de realizar sobre el software y aplicar esas tareas de una forma ordenada y efectiva. Una metodología es una manera sistemática de producir un software, con la finalidad de ayudar en:

- Adecuación: El sistema debe satisfacer las expectativas del usuario final.
- Mantenibilidad: El sistema debe ser capaz de ajustarse a nuevos cambios una vez que está en productivo en la empresa del cliente.
- Usabilidad: Es el grado de dificultad en aprender a manejar el sistema por parte de un usuario que no tiene por que ser programador. Irónicamente se puede decir que este atributo es inversamente proporcional a la resistencia al cambio.
- Fiabilidad: Es la capacidad de un sistema de funcionar correctamente durante un tiempo dado.
- Corrección: Densidad de defectos mínima.
- Eficiencia: Es la capacidad del sistema es capaz para realizar su tarea con el mínimo consumo de recursos necesario.

Para este trabajo terminal se decidió utilizar scrum como metodología debido a su flexibilidad y que está orientado a la realización de proyectos complejos, cómo aún no se sabe que algoritmo va a ser el que nos de un mejor resultado al momento de recomendar, scrum nos permite que en cada sprint podamos redefinir nuestra forma en la cuál vamos a llegar al resultado esperado, o en su defecto, al mejor resultado posible. Scrum ha sido ocupado para desarrollar software, hardware, software embebido, vehículos autónomos, etc. con un alto grado de éxito [20].

Scrum Es un proceso en el que se aplican de manera regular un conjunto de buenas prácticas para trabajar colaborativamente, en equipo y obtener el mejor resultado posible de proyectos, caracterizado por:

- Adoptar una estrategia de desarrollo incremental, en lugar de la planificación y ejecución completa del producto.
- Basar la calidad del resultado más en el conocimiento tácito de las personas en equipos auto organizados, que en la calidad de los procesos empleados.
- Solapar las diferentes fases del desarrollo, en lugar de realizar una tras otra en un ciclo secuencial o en cascada.

Scrum es apropiado para el desarrollo de este TT debido a que en lugar de decir como se deben de realizar las cosas, se sabe qué es lo que se debe realizar; la forma en la cómo se debe realizar puede ir cambiando dependiendo de las necesidades del equipo de trabajo, al ser un trabajo terminal de mucha investigación, el proceso en el cuál se debe llevar a cabo una tarea específica aún no está completamente detallado o bien definido.

En la figura 3 se muestra el proceso de Scrum, a continuación se mencionará como se aplicará cada uno en este trabajo terminal.

- Product Backlog: es la parte donde se definirán los requerimientos en cada una de las etapas del desarrollo del software hasta llegar a nuestro producto final, aquí se definen los tiempos estimados para cada sprint.
- Sprint Planning: aquí se determinará el avance en cada uno de los productos dentro del backlog, que se entregará para el siguiente sprint, también se definirá que parte del backlog se desarrollará y el tiempo necesario para llevarlo a cabo.
- Sprint Backlog: Aquí se seleccionarán los productos a realizar del product backlog, más un estimado del tiempo en que se van a realizar y un plan para lograr el objetivo del sprint.
- Daily Scrum: Es una junta diaria de máximo 15 minutos dónde cada uno de los desarrolladores planeará que se hará para las próximas 24 horas para poder cumplir con el objetivo del sprint y los puntos señalados en el sprint, aquí al ser un solo desarrollador únicamente se plantearán los objetivos del día.

- Product Backlog refinement: aquí se agregarán detalles y estimados para ordenar los elementos en el product backlog, se revisará el progreso de los elementos solicitados en el product backlog y si las pruebas de aceptación fueron exitosas.
- Sprint review: aquí se llevarán a cabo el incremento y adaptación del product backlog si se necesita, es decir se verá que se realizó con éxito del sprint y qué es lo siguiente a realizarse o tomarse en cuenta para el siguiente sprint planning.
- Sprint retrospective: aquí se analizará que se hizo bien en el sprint, que falló, cuales fueron las causas y que hay que mejorar para el próximo sprint.

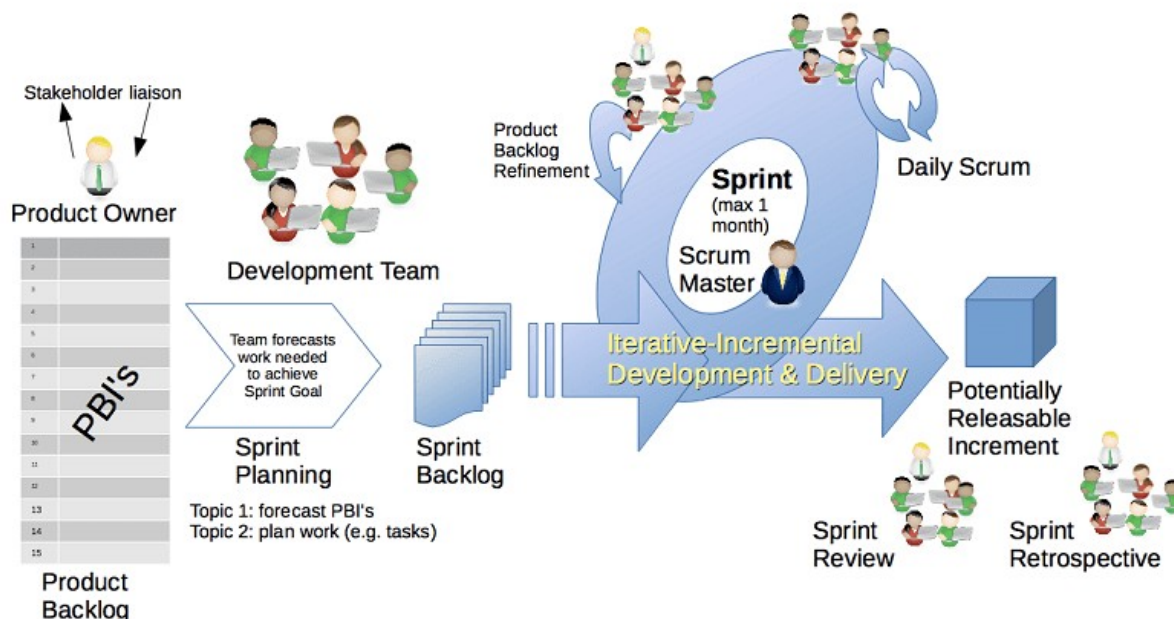


Figura 3. Modelo de desarrollo de software basado en la metodología ágil scrum [21]

6. Cronograma

Se anexa en la última hoja.

7. Referencias

- [1] Roby Segaran. Programming Collective Intelligence, Building Smart Web 2.0 Applications. USA: O'Reilly Media, 2008.
- [2] M. T. Hagan, Neural Network Design, Frisco, Texas: Martin T. Hagan, 1996.
- [3] Tara N. Sainath, Carolina Parada. "Convolutional Neural Networks for Small-footprint Keyword Spotting", 2015.
- [4] He Tong y Hu Yang. (2018). FashionNet: Personalized Outfit Recommendation with Deep Neural Network. Arxiv.
- [5] Singhal Ayush, Sinha Pradeep y Pant Rakesh. (2017). Use of Deep Learning in Modern Recommendation System: A Summary of Recent Works. *International Journal of Computer Applications*. 180(7). 17-20.
- [6] Chen Luyang, Yang Fan y Yang Heqing. Image-based Product Recommendation System with Convolutional Neural Networks. 1-6.
- [7] Fashion United (2017). Estadísticas de la industria de la moda en México. CDMX. *Fashion United*. Recuperado de: <https://fashionunited.mx/estadisticas-de-la-industria-de-la-moda-en-mexico>
- [8] Tula Miguel Esther (2019). 150.000 millones de prendas de ropa al año (y otras cifras en las que las tiendas no quieren que

- pienses). Madrid, España. *Magnet*. Recuperado de: <https://magnet.xataka.com/preguntas-no-tan-frecuentes/150-000-millones-prendas-ropa-al-ano-otras-cifras-que-tiendas-no-quieren-que-pienses>
- [9] Karün (2018). ¿Sabes cuánto contamina la industria de la moda?. USA. *Karün*. Recuperado de: <https://latam.karunworld.com/blogs/news/la-industria-de-la-moda>
- [10] Devashish Shankar, Sujay Narumanchi, Ananya H A, Pramod Kompalli y Krishnendu Chaudhury. (2017). Deep Learning based Large Scale Visual Recommendation and Search for E-Commerce. *Arvix*.
- [11] Lia Lia, Liu Yejun, Fu Jingtian, Ma Yihui, Huang Jie, Tong Zijian. (2018). Magic Mirror: A Virtual Fashion Consultant. *Proceedings of the 24th ACM international conference on Multimedia*. 680-683.
- [12] Sterling Bruce. (2011). Augmented Reality: Kinect fitting-room for TopShop. Moscow. *Wired*. Recuperado de: <https://www.wired.com/2011/05/augmented-reality-kinect-fitting-room-for-topshop-moscow/>
- [13] Matera Avery. (2018). Zara Introduces Augmented Reality Shopping App. USA. *TeenVogue*. Recuperado de: <https://www.teenvogue.com/story/zara-augmented-reality-shopping-app>
- [14] Cardoso Ângelo, Daolio Fabio y Vargas Saúl. (2018). Product Characterisation towards Personalisation. *Applied Data Science Track Paper*. 80-89.
- [15] Zhan Huijing, Shi Boxin, Chen Jiawei, Zheng Qian, Duan Ling-Yu y C. Kot Alex. Fashion Recommendation on street images. 280-284.
- [16] Ceballos Franciela (2018). Los mexicanos destinan casi un 9% del gasto a ropa y calzado, México. *Fashion Network*. Recuperado de: <https://mx.fashionnetwork.com/news/Los-mexicanos-destinan-casi-un-9-del-gasto-a-ropa-y-calzado,998641.html>
- [17] Dick, A.S., Basu, K.: Customer loyalty: toward an integrated conceptual framework. *J. Acad. Market. Sci.* 22 (2), 99–113 (1994).
- [18] Häubl, G., Murray, K.B.: Double agents: assessing the role of electronic product recommendation systems. *MIT Sloan Manag. Rev.* 47 (3), 8–12 (2006).
- [19] Tuinhof Hessel, Pirker Clemens y Haltmeier Markus. (2018). Image-Based Fashion Product Recommendation with Deep Learning. *Springer: Machine Learning Optimization and Data Science*. 472-481.
- [20] Schwaber Ken and Sutherland Jeff. (2017). *The Scrum Guide*. Recuperado de: <https://www.scrumguides.org/scrum-guide.html>
- [21] Stackify. (2017). What is Scrum? How Does Rugby Help Software Developers Create Quality Products?. Recuperado de: <https://stackify.com/what-is-scrum/>

8. Alumnos y Directores

Burciaga Ornelas Rodrigo Andrés.- Alumno de la carrera de Ing. en Sistemas Computacionales en ESCOM, Especialidad Sistemas, Boleta: 2013630445, Tel. 5523700007, email andii_burciaga@live.com

Firma:_____

Carlos A. Duchanoy.- Recibió el grado de Ingeniero en Mecatrónica por parte de la UPIITA del Instituto Politécnico Nacional, el grado de Maestro en Ciencias en Ingeniería de Cómputo y Doctor en Ciencias en Computación por parte del Centro en Investigación en Computación. Ha trabajado en la industria privada como Director de Investigación y Desarrollo en la empresa GusChat enfocado en el desarrollo de tecnologías para la comprensión del lenguaje natural para su uso en robots conversacionales. Actualmente es Catedrático CONACYT asignado como profesor visitante en Centro de Investigación en Computación. Su área de experiencia incluye Inteligencia Artificial, Redes Neuronales Profundas, Optimización y Diseño Mecatrónico Tel. celular: 55 12566602 ext. 56576, email duchduchanoy@gmail.com

Firma:_____

Suárez Castañón Miguel Santiago.- Dr. en C. de la Computación en el Instituto Politécnico Nacional en 2005, M. en C. de la Computación de la UNAM en 2001, Ing. en Cibernética y Ciencias de la Computación en la Universidad La Salle AC en 1991, Profesor de ESCOM/IPN (Sección de Estudios de Posgrado e Investigación) desde 2000. Miembro del Sistema Nacional de Investigadores Nivel I desde 2007. Co-autor de más de 25 artículos de investigación publicados en revistas contenidas el Journal Citation Reports. Áreas de Interés: Ingeniería de Software. Ext. 52043, Tel. celular 5550 689512, email sasuares@prodigy.net.mx.

Firma:_____

CARÁCTER: Confidencial
FUNDAMENTO LEGAL: Art. 3, fracc. II, Art. 18, fracc. II y
Art. 21, lineamiento 32, fracc. XVII de la L.F.T.A.I.P.G.
PARTES CONFIDENCIALES: No. de boleta y Teléfono.

TURNO PARA LA PRESENTACIÓN DEL
TRABAJO TERMINAL: Matutino

Nombre del alumno(a): Burciaga Ornelas Rodrigo Andrés

TT No.:

Título del TT: Aplicación Android para recomendación de prendas de vestir usando aprendizaje profundo

| Actividad | AGO | SEP | OCT | NOV | DIC | ENE | FEB | MAR | ABR | MAY | JUN |
|---|------------|------------|------------|------------|------------|------------|------------|------------|------------|------------|------------|
| Análisis y diseño de requerimientos del sistema, selección de tecnologías a utilizar e interfaces gráficas de usuario | | | | | | | | | | | |
| Identificación y especificación de algoritmos de procesamiento de visión por computadora | | | | | | | | | | | |
| Diseño arquitectura de software del sistema | | | | | | | | | | | |
| Generación del conjunto de datos para entrenar red neuronal de reconocimiento de objetos | | | | | | | | | | | |
| Recopilación de prendas a sugerir para llenado de base de datos | | | | | | | | | | | |
| Creación y llenado de la base de datos con prendas a sugerir | | | | | | | | | | | |
| Diseño y pruebas Red Neuronal Profunda para detección de objetos | | | | | | | | | | | |
| Diseño e implementación algoritmo de recomendación | | | | | | | | | | | |
| Evaluación TT 1 | | | | | | | | | | | |
| Retroalimentación y/o cambios TT 1 | | | | | | | | | | | |
| Implementación de Aprendizaje Profundo en interfaces gráficas | | | | | | | | | | | |
| Pruebas del algoritmo para recomendación de prendas | | | | | | | | | | | |
| Pruebas a interfaz de usuario y resultados de la integración con interfaces gráficas | | | | | | | | | | | |
| Documentación: Generación del Manual de Usuario y Manual Técnico, diagramas UML | | | | | | | | | | | |
| Evaluación de TT II. | | | | | | | | | | | |